

GB1 虚拟蛋白质定向进化智能体 · 实验报告

在 GB1 突变适应度地形上，用 ML 适应度预测器 + 五角色 LLM Agent 做闭环虚拟定向进化，并对四种推荐策略做诚实对比与失败分析。作者 ZeyuLi · 数据/代码可复现，完整实验入哈希链台账。

一句话结论：在 GB1 四位点地形上，随机策略明显最弱；模型贪心与 LLM Agent 都能在同一预算内逼近甚至达到全局最优 8.762（野生型=1.0）。但我们诚实地发现——**GB1 本身是一个可解地形**：即便只用 77 个单突变体冷启动，模型引导策略仍能在第 2 轮达峰。因此“能否达峰”不是区分点，真正的区分点是**样本效率与批次产出质量**：此处 Agent 的聚焦组合库在每种设定下都 $\geq$ 模型贪心（强命中 56—57 vs 43），而知识增强只带来轻微改变。

一、背景与问题定义

蛋白质定向进化通过“设计→构建→测试→学习”(DBTL)循环迭代寻找高适应度序列；真实湿实验成本高，故用已测数据训练**适应度预测器**作为“虚拟实验评估器”，让智能体在计算机内提出下一轮突变。本项目要求：(1) 处理真实 GB1 突变-fitness 数据；(2) 训练适应度预测模型；(3) 设计模块化的**五角色 LLM Agent** 提出突变；(4) 引入**知识增强**并做消融；(5) 做 2—3 轮虚拟进化；(6) 对比**随机 / 模型贪心 / LLM Agent / 知识增强 Agent** 四种策略并分析成功与失败案例。核心问题：*结构化的 Agent 推理 + 领域知识，是否真的比“直接调用预测模型”更好？*

二、数据集介绍

采用 **GB1**（蛋白 G 的 B1 结构域）四位点组合突变库（Wu et al., 2016）。四个可变位点 **V39 / D40 / G41 / V54**，野生型序列 **VDGV**（适应度归一化为 **1.0**）。理论组合 $20^4 = 160,000$ ，实测有真值的 **149,361** 个；缺失 **10,639** 个为真实无测量数据（非人为剔除），报告中明确记为已知局限。

全局最优变体为 **FWAA**（V39F/D40W/G41A/V54A，与 WT 汉明距离 **HD=4**），适应度 **8.762**——即四个位点相对 WT 全部突变。

按汉明距离	变体数
HD=1（单突变）	76
HD=2（双突变）	2,091
HD=3（三突变）	26,019
HD=4（四突变）	121,174
合计（可测）	149,361

注：随机采样四位点变体几乎必然 HD=4（每位点独立取 20 种氨基酸），这一点在实验设定中很关键（见第六、七章）。

三、适应度预测模型

特征采用两种：**one-hot**（4 位点 $\times$ 20 氨基酸 = 80 维）与 **ESM-2**（650M 蛋白语言模型，1280 维 mean-pooled 嵌入）。模型采用**阶梯**：Ridge / 梯度提升(XGBoost 缺失时回退 GradientBoosting) / MLP，各以 5 seed 深度集成给出均值与方差（供 Agent 做 UCB 探索）。指标：Spearman / Pearson / MSE / Top-k 命中率。

我们特别设置两种切分对比泛化能力：**随机切分**（分布内）与 **HD 外推切分**（训练仅 HD $\leq$ 2 的 2,168 个低阶突变，测试 HD $\geq$ 3 的高阶突变——模拟“用低阶数据预测高阶组合”的真实困难）。

切分 $\times$ 特征	Ridge	XGB	MLP	说明
随机 · one-hot	0.484	0.474	0.389	分布内，两特征相当
随机 · ESM-2	0.493	0.377	0.491	分布内，ESM 略优
外推 · one-hot	0.358	0.354	0.278	外推显著变差
外推 · ESM-2	0.404	0.352	0.493	ESM 外推明显更稳

核心发现（预测器）：分布内两种特征相当（Spearman $\sim$ 0.48—0.49）；但在 **HD 外推**下，ESM-2 显著优于 one-hot——MLP Spearman **0.493 vs 0.278**，Ridge 的 MSE **0.188 vs 0.483**。即蛋白语言模型嵌入把“看过低阶、预测高阶”的泛化能力提上来了。这为后续 Agent 在外推设定下仍能工作提供了基础。

四、LLM Agent 设计

采用模块化五角色流水线（Pydantic schema 校验每个角色的输入/输出），LLM 仅注入两个端口，其余为确定性、可审计逻辑：

- **Data Analyst**：统计训练池中各位点/替换的观测适应度，产出位点收益画像。
- **Hypothesis Generator**（LLM 端口）：基于分析证据提出最值得组合的替换；无 LLM 或调用失败时回退到“按观测均值取每位点 top-8 替换”的确定性生成器。
- **Mutation Designer**：把假设枚举为**组合库**（每位点至多一个替换、排除全 WT、修复同位点冲突），交下游打分。
- **Fitness Evaluator**：调预测器给每个候选出（均值, 方差）。
- **Scientific Critic**（LLM 端口 + 知识规则）：按规则校验候选、接受/拒稿并给理由；`--no-knowledge` 消融时关闭知识门。

每个角色的动作都追加到**哈希链事件流**（append-only + SHA-256 链 + fsync），可被 `verify()` 校验、可在前端 demo 回放——这既是可审计性，也是“展示 Agent 推理过程”的数据底座。LLM 端口接自有 OpenAI 兼容模型池（本报告用 `claude-sonnet-5`），无凭据/超时时自动降级为确定性生成器，因此项目**离线也能完整复现**；每轮记录该轮用的是 LLM 还是 fallback。

五、知识增强方法

知识增强在两处体现：(1) **突变规则**（合法位点 R-GB1-SITES、 ≤ 4 突变 R-MAX-MUTATIONS、无终止子）由 Mutation Designer 结构性保证 + Critic 校验；(2) 在采集函数中叠加 **BLOSUM62 保守性软先验** 与 **UCB 探索**：知识增强 Agent 的候选打分 = 预测均值 + $0.75 \cdot \sqrt{\text{方差}}$ + $0.3 \cdot \text{BLOSUM62 先验}$ （偏好保守替换）。`--no-knowledge` 消融同时去掉 UCB 与 BLOSUM 先验，退化为“聚焦组合库 + 纯预测均值”。BLOSUM62、氨基酸理化性质、突变规则与知识图谱构成知识库，规则拒稿能力由单测与 demo 演示。

六、虚拟定向进化实验结果

四策略在**同一预算**（每轮 96 孔，3 轮）、**同一 oracle**（真值查表，非模型自评）、**同一提名空间**（149,361 可测变体）下对比。为诚实评估难度，设三档冷启动：**easy**（随机池， $\approx 98\%$ 已是 $\text{HD} \geq 3$ 高阶）、**hard**（仅 $\text{HD} \leq 2$ 冷启动、外推到 $\text{HD} \geq 3$ ）、**sparse**（仅 77 个 $\text{HD} \leq 1$ 单突变冷启动）。

设定 / 策略	random	greedy	agent	knowledge
easy 累计最优	2.37	8.045	8.762	8.762
hard 累计最优	5.08	8.762	8.762	8.762
sparse 累计最优	3.99	8.762	8.762	8.762
hard 强变体数(≥ 4)	1	43	56	57
hard 有益命中(>1)	7	154	187	190




图 1 · hard (HD≤2 外推) 设定下四策略逐轮累计最优适应度。random 停在低位；greedy/agent/knowledge 均在第 2 轮达全局最优 8.762。

逐轮 Top-k 与关键位点

各策略最终 Top-10 的位点画像揭示不同策略集中在不同位点组合：**模型贪心收敛到 G41→C、V54→A**（10/10 一致，强开发但错过真峰所需的 D40→W）；**Agent 集中在 V39→F、D40→W**（芳香族替换），正是全局峰 FWAA 的组分。推荐突变确实“集中在关键位点”，且 Agent 的聚焦方向与真峰更契合。

七、失败案例分析

诚实的元发现：GB1 四位点地形本身可解。我们用极稀疏的 77 个单突变体冷启动，greedy 与两个 Agent 仍在第 2 轮达全局峰 8.762。这说明该地形上位效应有限、低阶数据足以外推到四阶峰——因此“达峰”不能作为方法优劣的判据，这是 GB1 的性质，不是作弊：全局峰 FWAA 不在任何冷启动池内、oracle 为真值查表（题目允许的虚拟评估器）。

- **随机策略的系统性失败：**三档下 random 累计最优仅 2.37–5.08，强变体近乎为零——无预测器引导时，16 万空间里靠运气无法系统逼近峰。这是必要的**阴性对照**，说明 ML 引导不可或缺。
- **我们自己的一个真 bug（已修）：**组合库最初有 LIBRARY_CAP=2000 的字典序截断，会在预测器打分前把真峰所在组合排除出库，导致 hard 设定下 Agent 一度只到 7.23。定位根因（峰四个替换都在假设里、但组合被截断）后将上限提到覆盖全部组合（≤6561），Agent 随即达峰。这是“失败→定位→修复”的完整链条，也说明结论对实现细节敏感、须以事件流/台账追溯。
- **知识增强收益有限：**knowledge 与 no-knowledge 几乎持平（hard 强变体 57 vs 56）。原因是预测器已捕获主要信号，BLOSUM 保守先验只是轻扰动；在偏好非保守高阶替换的 GB1 上，保守先验甚至可能与增益方向相悖。这是对“知识增强必然更好”的诚实否定。
- **模型贪心的“开发过度”：**easy 设定下 greedy 停在 8.045、错过真峰，因为它对预测器高置信区域过度开发（全收敛到 G41C/V54A），而 Agent 的聚焦组合库跳出该局部、覆盖到真峰组分。

Agent 是否真学到“科学家思维”，还是只是调用预测模型？诚实的回答：在本任务上，Agent 更像一个**结构化、可审计的搜索启发式**——它把“分析证据→提出假设→设计组合库→打分→按规则批判”固化为可回放的流程，并在每种设定下以更高的批次产出优于纯贪心；但它**不是自主的科学推理**，其“智能”主要来自预测器与组合库结构，LLM 端口与知识先验是轻量增益而非决定因素。把这一点讲清楚，本身就是对题目的正面回答。

八、改进建议与未来拓展

- **更难的地形与目标**：GB1 四位点偏易；换更长/更强上位的地形（如 GFP、 β -lactamase、AAV），或把目标设为“最少湿实验轮数达到 95% 峰值”，才能真正拉开策略差距。
- **让知识真正发力**：把知识从“软先验”升级为“约束假设生成 + 知识图谱驱动的位点/组合优先级”，并在预测器弱（HD 外推）时加大知识权重。
- **预测器不确定性驱动主动学习**：用 ESM-2 + 深度集成方差做更激进的 UCB/Thompson 采样，量化“样本效率”（达到目标所需测量数）。
- **LLM 深度参与**：让 LLM 端口不止提假设，还参与失败复盘与下一轮策略调整（真正的 DBTL 闭环推理），并对比不同模型档位。
- **严谨评估**：多 seed 置信区间、逐轮样本效率曲线、与文献 ML-guided DE 基线对齐。

附录 · 外部资源与复现

数据：GB1 四位点适应度数据（Wu, Kang, Otwinowski, et al., 2016, 公开数据集），本地校验后使用，未做清洗。模型：ESM-2 `esm2_t33_650M_UR50D`（Meta AI, 开源）用于序列嵌入；scikit-learn 的 Ridge/GradientBoosting/MLP。LLM：自有 OpenAI 兼容模型池（`claude-sonnet-5`）经可注入端口调用，凭据置于本地 `.env`（不入库），缺失即离线降级。复现：`python -m evolution.campaign --seed 42 --cold-start low_hd`（hard 档）等命令产出 `reports/campaign_metrics*.json` 与哈希链事件流；预测器对比见 `reports/predictor_metrics.json`。全部实验运行追加到 `append-only` 哈希链台账 `reports/experiment_log.jsonl`，可 `verify()` 审计。代码开源，README 载运行环境、数据来源与命令。